Case Data Master Santander

Engenharia de Dados: Data Warehouse

Fernando Miguel D’Andrea Lima

GitHub: https://github.com/fernandomiguel99/case_data_master_data_eng

Objetivos

Implementação de uma Data Warehouse;

Estrutura de camadas “Medallion”;

Consumo e verificação dos dados.

Estrutura utilizada

Databricks SQL Warehouse

- ❑Estrutura Lakehouse;
- ❑Processamento Serverless;
- ❑Volumes, Schemas e Catalogs;
- ❑Alertas via e-mail de erros em processos;
- ❑Integração com ambiente PowerBi.

GitHub

- ❑Versionamento de Código;
- ❑Colaboração;
- ❑Segurança.

Fonte de Dados

Fonte de Dados: BNDES;

Base de dados pública com as informações de financiamentos não automáticas;

Base com tempestividade mensal, com informações sobre o destino do financiamento, cliente, prazo, taxas, valores e intermediários.

Dados extraídos em formato CSV.

https://dadosabertos.bndes.gov.br/dataset/operacoes-financiamento

ELT & Processamento

Modelo de Dados: ELT(Extract, Load, Transform);

Ambiente Databricks:

- Volume para receber e salvar os .CSVs;
- Python Notebooks para tratamentos e processamentos;
- Job Pipeline automatizado como orquestrador de Tasks;
- Schema e Data Catalog para gestão e controle de acessos;
- Mascaramento de Dados Sensíveis.

Estrutura Medallion:

- Camada Bronze: Base importada do CSV com imposição do Schema;
- Camada Silver: Base com campos selecionados e tratados e duplicadas regularizadas;
- Camada Gold: Base final pronta para consumo no PowerBi.

Visualização e Resultados

- Conexão da Camada Gold com Power BI;
- Atualização Automática(DirectQuery) ou On-Demand;
- Alta Customização de visuais e integração Embedded em websites.

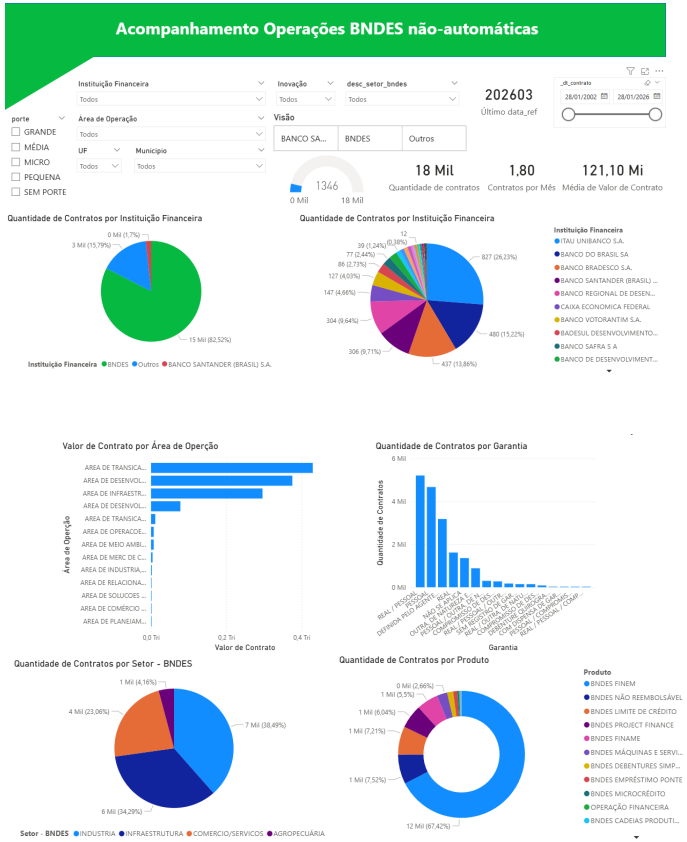

Visualização e Resultados

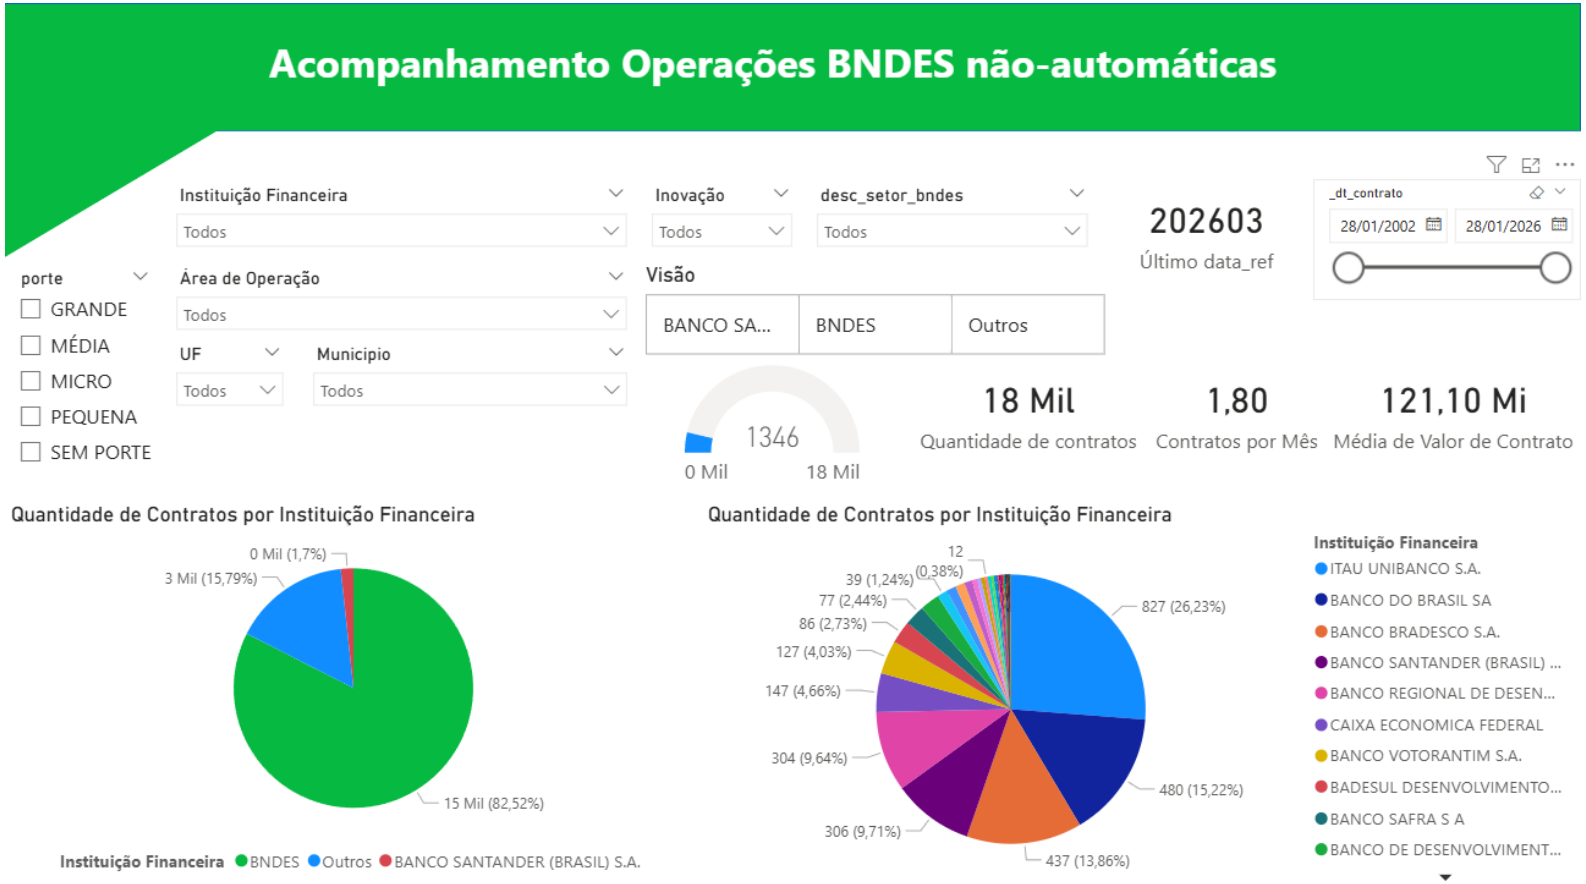

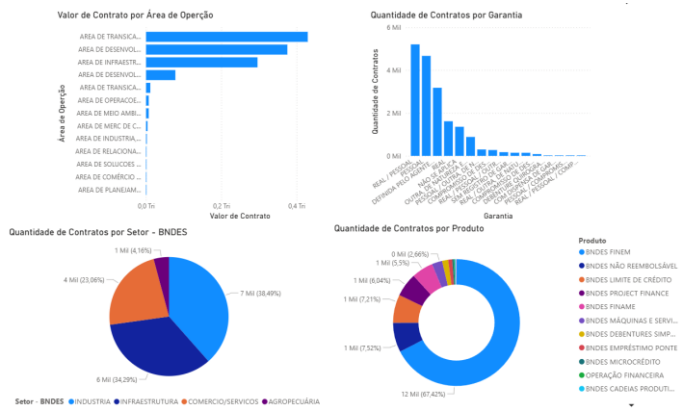

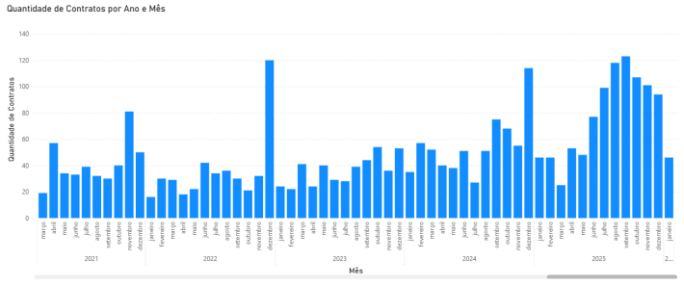

Visualização e Resultados

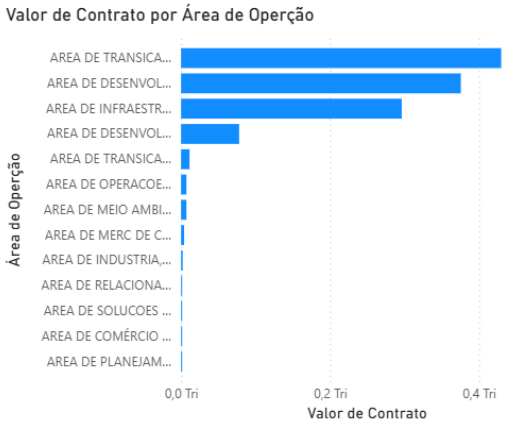

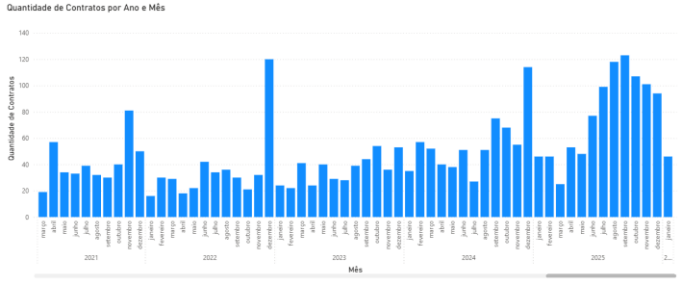

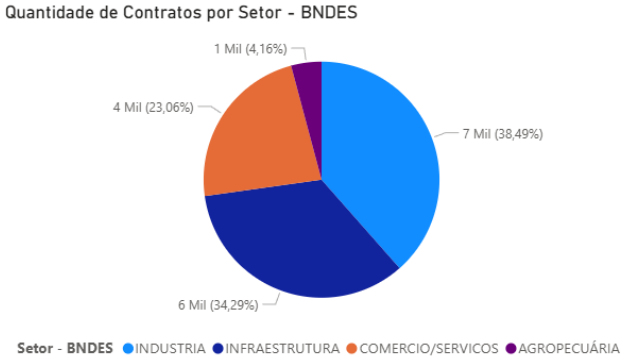

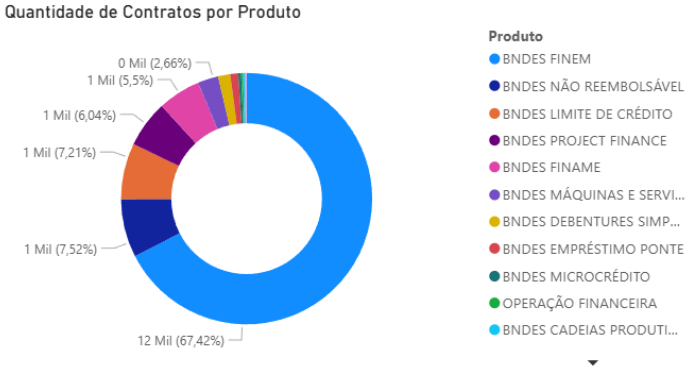

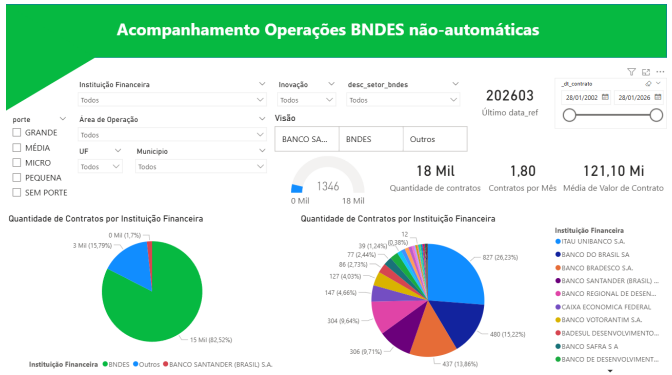

Visualização e Resultados

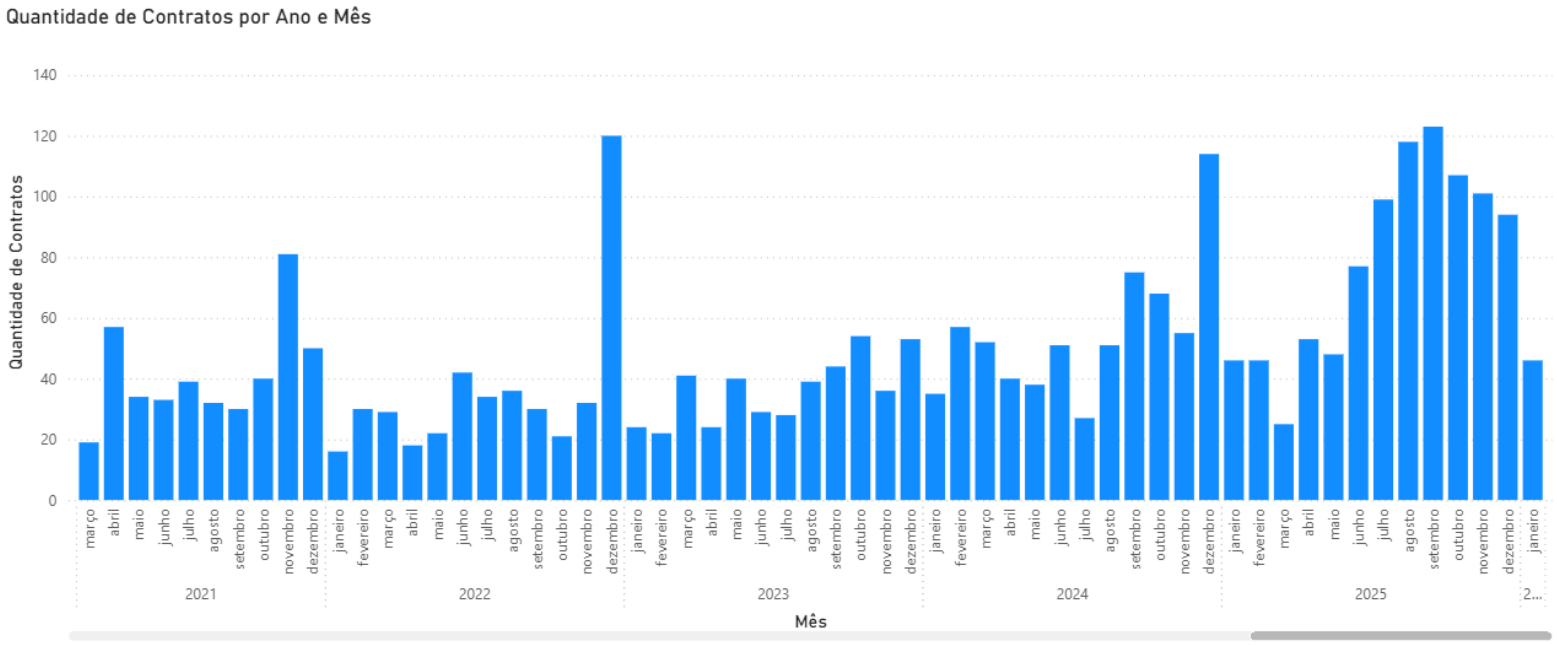

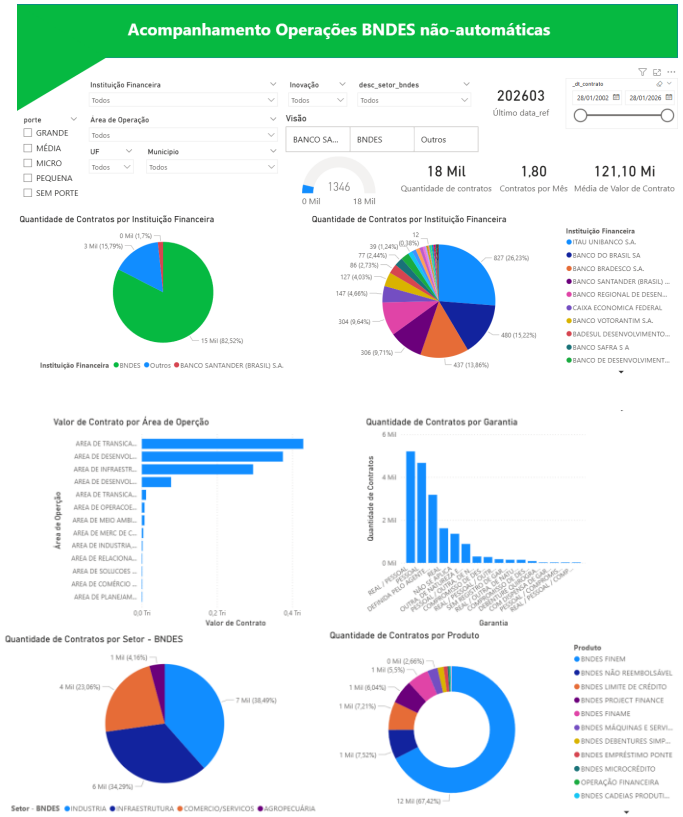

Dificuldades e Melhorias

- Substituição da ingestão via arquivos .CSV por uma comunicação direta via API, removendo o risco operacional da carga manual.

- Implementação de criptografia baseada em técnicas de HASH, a fim de reforçar a segurança e garantir a conformidade com a LGPD.

- Criação de um script completo de configuração do ambiente de Data Warehouse, incluindo definição de grupos, regras de acesso e políticas, permitindo fácil acesso à prototipação do projeto.